

Model-based learning

Projet sous le logiciel R - 2026-2027

L'objectif du projet est de créer un package R permettant de réaliser un co-clustering de données ordinales.

L'algorithme Le modèle considéré sera le modèle des blocs latents, avec comme composante de base le modèle CUB pour données ordinales, vu en cours. L'inférence sera réalisée par un algorithme SEM, et le critère ICL sera utilisé pour sélectionner le nombre de blocs. Votre fonction de co-clustering devra prendre en entrée :

- les données,
- le nombre de clusters en ligne et en colonne,
- le nombre d'initialisation aléatoires (20 par défaut).

Pour chaque estimation de modèle, des initialisations aléatoires multiples seront implémentées en interne de la fonction, et la meilleure solution sera retournée.

En sortie, l'algorithme devra retourner :

- les probabilités d'appartenances des lignes et colonnes à chaque cluster ligne et cluster colonne,
- l'affectation des lignes et colonnes aux clusters ligne et colonne,
- la valeur du critère ICL,
- les paramètres estimés du modèle.

Le package Votre fonction R devra être incorporée à un package R.

Comme tout package R il devra comporter une aide pour votre fonction, incluant un exemple d'utilisation.

Livrable

- un package R (en format `.tar.gz` que je puisse installer sans soucis sur mon Mac),
- une vignette pour votre package R illustrant l'utilisation de votre package,
- un oral au cours duquel je vous demanderai de m'expliquer certaines parties de votre code. Vous pouvez donc utiliser une IA si vous le souhaitez, mais vous devez être en mesure d'en comprendre chaque ligne de code.